

65

命題 49 の証明

任意の $g = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} a_{i,j} e_{X,i}(x) e_{Y,j}(y) \in H_X \otimes H_Y$, $(x, y) \in E$ について、その評価値が有界である。実際、

$$|g(x, y)| \leq \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} |a_{i,j}| \cdot |e_{X,i}(x)| \cdot |e_{Y,j}(y)| \leq \sum_{i=1}^{\infty} |e_{X,i}(x)| \cdot \left(\sum_{j=1}^{\infty} e_{Y,j}^2(y) \right)^{1/2} \left(\sum_{j=1}^{\infty} a_{i,j}^2(y) \right)^{1/2} \quad (5.21)$$

となる ($\sum_{j=1}^{\infty}$ に関して Cauchy-Schwarz の不等式(2.5)を用いた)。ここで、 $k_Y(y, \cdot) = \sum_j h_j(y) e_{Y,j}(\cdot)$ とおくと、 $\langle e_{Y,i}(\cdot), k_Y(y, \cdot) \rangle = e_{Y,i}(y)$ より、 $h_i(y) = e_{Y,i}(y)$ となり、 $k_Y(y, \cdot) = \sum_{j=1}^{\infty} e_{Y,j}(y) e_{Y,j}(\cdot)$

が成立する。したがって、

$$\sum_{j=1}^{\infty} e_{Y,j}^2(y) = k_Y(y, y) \quad (5.22)$$

および

$$\sum_{i=1}^{\infty} |e_{X,i}(x)| \cdot \left(\sum_{j=1}^{\infty} a_{i,j}^2 \right)^{1/2} \leq \left(\sum_{i=1}^{\infty} e_{X,i}^2(x) \right)^{1/2} \left(\sum_{i=1}^{\infty} \sum_{j=1}^{\infty} a_{i,j}^2 \right)^{1/2} = \sqrt{k_X(x, x)} \|g\| \quad (5.23)$$

が成立する ($\sum_{i=1}^{\infty}$ に関して Cauchy-Schwarz の不等式(2.5)を用いた)。(5.21)–(5.23) は、 $|g(x, y)| \leq \sqrt{k_X(x, x)} \sqrt{k_Y(y, y)} \|g\|$ を意味する。したがって、 $H_X \otimes H_Y$ は RKHS である。

そして、 $k(x, x', y, y') := k_X(x, x') k_Y(y, y')$ は、 $k_X(x, \cdot) \in H_X$, $k_Y(y, \cdot) \in H_Y$ より、 $k(x, \cdot, y, \star) := k_X(x, \cdot) k_Y(y, \cdot) \in H_X \otimes H_Y$ が成立する。さらに、

$$\begin{aligned} g(x, y) &= \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} a_{i,j} e_{X,i}(x) e_{Y,j}(y) = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} a_{i,j} \langle e_{X,i}(\cdot), k_X(x, \cdot) \rangle_{H_X} \langle e_{Y,i}(\star), k_Y(y, \star) \rangle_{H_Y} \\ &= \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} a_{i,j} \langle e_{X,i}(\cdot) e_{Y,j}(\star), k(x, \cdot, y, \star) \rangle_H = \left\langle \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} a_{i,j} e_{X,i}(\cdot) e_{Y,j}(\cdot), k(x, \cdot, y, \star) \right\rangle_H \\ &= \langle g(\cdot, \star), k(x, \cdot, y, \star) \rangle \end{aligned}$$

より、 k は $H_X \otimes H_Y$ の再生核である。 \square

a

b

c

66. $\mathbb{E}[k_x(x, \cdot)]$ と $\mathbb{E}[k_Y(Y, \cdot)]$ は有限であると仮定する。このとき、
 $k_x(x, \cdot) k_Y(Y, \cdot) \in H_x \otimes H_Y$ が X, Y の同時分布で平均を
 とった $\mathbb{E}_{XY}[k_x(x, \cdot) k_Y(Y, \cdot)]$ は \leq

$$\begin{aligned} \mathbb{E}_{XY}[\|k_x(x, \cdot) k_Y(Y, \cdot)\|_{H_x \otimes H_Y}] &= \mathbb{E}_{XY}[\|k_x(x, \cdot)\|_{H_x} \|k_Y(Y, \cdot)\|_{H_Y}] \\ &= \mathbb{E}_{XY}[\sqrt{k_x(x, x) k_Y(Y, Y)}] \\ &\leq \sqrt{\mathbb{E}_x[k_x(x, x)] \mathbb{E}_Y[k_Y(Y, Y)]} \end{aligned}$$

なぜか。この左辺(は仮定)有限の値をとる。なぜか?
 $f \in H_x \otimes H_Y$ に対して、

$$\begin{aligned} \mathbb{E}_{XY}[f(X, Y)] &= \mathbb{E}_{XY}\langle f, k_x(x, \cdot) k_Y(Y, \cdot) \rangle \\ &\leq \|f\|_{H_x \otimes H_Y} \mathbb{E}_{XY}[\|k_x(x, \cdot) k_Y(Y, \cdot)\|_{H_x \otimes H_Y}] \end{aligned}$$

が成立し, Riesz の表現定理より、

$$\mathbb{E}_{XY}[f(X, Y)] = \langle f, m_{XY} \rangle$$

を満たす $m_{XY} \in H_x \otimes H_Y$ が存在する。

このように平均を定義する。

67. 任意の $g \in H_Y$ に対して、線形写像

$$Tg : H_X \ni f \mapsto \langle fg, m_{XY} - m_X m_Y \rangle_{H_X \otimes H_Y} \in \mathbb{R}$$

$$\text{(1). } \langle fg, m_{XY} - m_X m_Y \rangle_{H_X \otimes H_Y}$$

$$\leq \|f\|_{H_X} \|g\|_{H_Y} \|m_{XY} - m_X m_Y\|_{H_X \otimes H_Y}$$

す) 有界である, Riesz の表現定理 す),

$$Tg f = \langle f, h_g \rangle_{H_X} なる h_g \in H_X が存在する。すなれば,$$

$$\langle fg, m_{XY} - m_X m_Y \rangle_{H_X \otimes H_Y} = \langle f, \sum_{x \in Y} g \rangle_{H_X}$$

すなはち $\sum_{x \in Y} : H_Y \ni g \mapsto h_g \in H_X$ が存在する。

すなはち,

$$\|\sum_{x \in Y} g\|_{H_X} = \|h_g\|_{H_X} = \|Tg\| \leq \|g\|_{H_Y} \|m_{XY} - m_X m_Y\|_{H_X \otimes H_Y}$$

す) $\sum_{x \in Y}$ は有界である。 (2)

$$68 \quad \mathcal{F} := \{f \in \mathcal{H} \mid \|f\|_{\mathcal{H}} \leq 1\}$$

$$\text{MMD} := \sup_{f \in \mathcal{F}} |\mathbb{E}_p[f(x)] - \mathbb{E}_q[f(x)]|$$

このとき、

$$\text{MMD}^2 = \sup_{f \in \mathcal{F}} |\langle m_p, f \rangle - \langle m_q, f \rangle|^2$$

$$= \sup_{f \in \mathcal{F}} |\langle m_p - m_q, f \rangle|^2 = \|m_p - m_q\|_H^2$$

良いナスは？

が、(MMD = \|m_p - m_q\|_H は言え?)

なぜなら、 x' は x と、 (y', y) 同一の分布に従う独立な観測値とする。

このとき、

$$\begin{aligned} \text{MMD}^2 &= \langle m_p, m_p \rangle^2 + \langle m_q, m_q \rangle^2 - 2 \langle m_p, m_q \rangle \\ &= \langle \mathbb{E}_x[\kappa(x, \cdot)], \mathbb{E}_x[\kappa(x', \cdot)] \rangle + \langle \mathbb{E}_y[\kappa(y, \cdot)], \mathbb{E}_y[\kappa(y', \cdot)] \rangle \\ &\quad - 2 \langle \mathbb{E}_x[\kappa(x, \cdot)], \mathbb{E}_y[\kappa(y, \cdot)] \rangle \\ &= \mathbb{E}_{xx}[\kappa(x, x')] + \mathbb{E}_{yy}[\kappa(y, y')] - 2 \mathbb{E}_{xy}[\kappa(x, y)] \end{aligned}$$

が、(R)

(R)

69.

$$\frac{1}{m(m-1)} \sum_{i=1}^m \sum_{j \neq i} k(x_i, x_j) + \frac{1}{n(n-1)} \sum_{i=1}^n \sum_{j \neq i} k(y_i, y_j) - \frac{2}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j) \quad (5.4)$$

が、MMD² の不偏推定量であることを示す。

まず、68. 5).

$$MMD^2 = E_{xx'}[k(x, x')] + E_{yy'}[k(y, y')] - 2E_{xy}[k(x, y)]$$

が成り立つ。

$$\begin{aligned} & E\left[\frac{1}{m(m-1)} \sum_{i=1}^m \sum_{j \neq i} k(x_i, x_j)\right] \\ &= \frac{1}{m} \sum_{i=1}^m E_{x_i}\left[\frac{1}{m-1} \sum_{j \neq i} k(x_i, x_j)\right] \quad (\because \text{期待値の線形性}) \\ &= E_{xx'}[k(x, x')] \end{aligned}$$

でし), 第二項も同様に,

$$\begin{aligned} & E\left[\frac{1}{n(n-1)} \sum_{i=1}^n \sum_{j \neq i} k(y_i, y_j)\right] = E_{yy'}[k(y, y')] \text{ でし), そして,} \\ & E\left[\frac{1}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j)\right] = \frac{1}{mn} \sum_{i=1}^m \sum_{j=1}^n E_{x_i y_j}[k(x_i, y_j)] \\ &= E_{xy}[k(x, y)] \end{aligned}$$

ゆえに,

$$E[(5.4)] = MMD^2 \quad \text{が成り立つ。}$$

□

```
"""問題70"""
from pathlib import Path

import matplotlib.pyplot as plt
import numpy as np
from scipy.stats import gaussian_kde

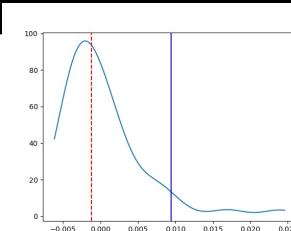
sigma = 1
def k(x: np.ndarray, y: np.ndarray) -> float:
    """ガウシアンカーネル"""
    return np.exp(-(x - y)**2 / (2 * sigma**2))

# データの生成
m = 150
n = 100
rs = np.random.RandomState(42)
xx = rs.randn(m)
yy = rs.randn(n)

# 帰無分布の計算
T: list[float] = []
for _ in range(100):
    index1 = rs.choice(m, size=int(m/2), replace=False)
    index2 = rs.choice(n, size=int(n/2), replace=False)
    x_perm = np.concatenate((xx[index1], yy[index2]))
    y_perm = np.concatenate((xx[np.setdiff1d(np.arange(m), index1)], yy[np.setdiff1d(np.arange(n), index2)]))
    m_x_perm = x_perm.shape[0]
    n_y_perm = y_perm.shape[0]
    # (5.4)の計算
    term1 = sum(k(x_perm[i], x_perm[j]) for i in range(m_x_perm) for j in range(m_x_perm) if i != j) / (m_x_perm * (m_x_perm - 1))
    term2 = sum(k(y_perm[i], y_perm[j]) for i in range(n_y_perm) for j in range(n_y_perm) if i != j) / (n_y_perm * (n_y_perm - 1))
    term3 = sum(k(x_perm[i], y_perm[j]) for i in range(m_x_perm) for j in range(n_y_perm)) * 2 / (m_x_perm * n_y_perm)
    T.append(term1 + term2 - term3)
v = np.quantile(T, 0.95)

# 統計量の計算
term1 = sum(k(xx[i], xx[j]) for i in range(m) for j in range(m) if i != j) / (m * (m - 1))
term2 = sum(k(yy[i], yy[j]) for i in range(n) for j in range(n) if i != j) / (n * (n - 1))
term3 = sum(k(xx[i], yy[j]) for i in range(m) for j in range(n)) * 2 / (m * n)
u = term1 + term2 - term3

# グラフの図示
x = np.linspace(min(*T, u, v), max(*T, u, v), 200)
density = gaussian_kde(T)
plt.plot(x, density(x))
plt.axvline(x=u, c="r", linestyle="--")
plt.axvline(x=v, c="b")
filename = Path("src/exercise/Chap5/out/problem70/result.png")
filename.parent.mkdir(parents=True, exist_ok=True)
plt.savefig(filename)
```



71. 帰無假説 $X = Y$ の下で、

$h_1 \equiv 0$ (恒等的 $\Rightarrow 0$ である関数) とす。

$$h_1(Z_i) = E_{Z_2}[h(Z_i, Z_2)]$$

$$= E[R(X_i, X_j)] + E[R(Y_i, Y_j)] - E[R(X_i, Y_j)] - E[R(Y_i, X_j)]$$

$$= 0 \quad \square$$

すなはち $\hat{h}_1 \equiv h_1$ とす。

帰無假説の下で、

$$(1) := E[h(Z_1, \dots, Z_m)] = 0 \text{ である},$$

$$\tilde{h}_c(Z_1, \dots, Z_c) := h_c(Z_1, \dots, Z_c) - 0$$

であるので

$$\tilde{h}_2(Z_1, Z_2) = h_2(Z_1, Z_2) \quad \text{である} \quad \square$$

72. $X \sim N(\mu_x, \sigma_x^2)$, $Y \sim N(\mu_y, \sigma_y^2)$ とする。

(i) X と Y が 独立 $\Rightarrow \rho_{XY} = 0$ を示す。

X と Y が 独立であるとき, $E[XY] = E[X]E[Y]$ が成り立つ。

$$\text{Cov}[X, Y] = E[XY] - E[X]E[Y] = 0 \quad \text{である。}$$

$$\text{よって, } \rho_{XY} = \frac{\text{Cov}[X, Y]}{\sigma_X \sigma_Y} = 0 \quad \text{である。}$$

(ii) $\rho_{XY} = 0 \Rightarrow X$ と Y が独立を示す。

$$f_{XY}(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho_{XY}^2}} \exp\left\{-\frac{1}{2(1-\rho_{XY}^2)}\left(\frac{x^2}{\sigma_X^2} + \frac{y^2}{\sigma_Y^2} - \frac{2\rho_{XY}xy}{\sigma_X\sigma_Y}\right)\right\}$$

であるが、 $\rho_{XY} = 0$ のとき、

$$f_{XY}(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y} \exp\left\{-\frac{1}{2}\left(\frac{x^2}{\sigma_X^2} + \frac{y^2}{\sigma_Y^2}\right)\right\} = f_X(x)f_Y(y).$$

であるから、 X と Y が独立である。

以上・(i), (ii) より 示す。

73. $\theta \sim U(0, 2\pi)$, $X = \cos \theta$, $Y = \sin \theta$ とする。このとき、

X ~~と~~ Y である。 -1

$$\text{Cov}[X, Y] = E[XY] - E[X]E[Y] = E[\cos\theta \sin\theta] = \frac{1}{2}E[\sin 2\theta] = 0$$

$$\text{である, } \rho_{XY} = \frac{\text{Cov}[X, Y]}{\sigma_X \sigma_Y} = 0 \quad \text{である。}$$

73. $\| \cdot \|_{X \otimes Y}, \langle \cdot, \cdot \rangle_{X \otimes Y} \in \|\cdot\|, \langle \cdot, \cdot \rangle$ の弱定理

$$\begin{aligned}\|m_{XY}\|^2 &= \langle E_{XY}[k_X(x, \cdot) k_Y(Y, \cdot)], E_{XY}[k_X(x, \cdot) k_Y(Y, \cdot)] \rangle \\ &= E_X E_Y \langle k_X(x, \cdot) k_Y(Y, \cdot), k_X(x, \cdot) k_Y(Y, \cdot) \rangle \\ &= E_{XXYY} [k_X(x, x') k_Y(Y, Y')] ,\end{aligned}$$

$$\langle m_{XY}, m_X m_Y \rangle$$

$$\begin{aligned}&= \langle E_{XY}[k_X(x, \cdot) k_Y(Y, \cdot)], E_X[k_X(x, \cdot)] E_Y[k_Y(Y, \cdot)] \rangle \\ &= E_{XY} \left[E_X[\langle k_X(x, \cdot) k_Y(Y, \cdot), k_X(x', \cdot) E_Y[k_Y(Y, \cdot)] \rangle] \right] \\ &= E_{XY} \left[E_X[k_X(x, x')] E_Y[\langle k_Y(Y, \cdot), k_Y(Y, \cdot) \rangle] \right] \\ &= E_{XY} \left[E_X[k_X(x, x')] E_Y[k_Y(Y, Y')] \right],\end{aligned}$$

$$\|m_X m_Y\|^2$$

$$\begin{aligned}&= \langle E_X[k_X(x, \cdot)] E_Y[k_X(Y, \cdot)], E_X[k_X(x', \cdot)] E_Y[k_Y(Y', \cdot)] \rangle \\ &= E_X E_X[k_X(x, x')] E_Y E_Y[k_Y(Y, Y')]\end{aligned}$$

である。

$$\begin{aligned}\|m_{XY} - m_X m_Y\|^2 &= \|m_{XY}\|^2 - 2 \langle m_{XY}, m_X m_Y \rangle + \|m_X m_Y\|^2 \\ &= (\bar{x}_1, \bar{y}_1, \bar{x}_2, \bar{y}_2; (5, 9)) .\end{aligned}$$

74. trace 計算を証明

$$\text{tr}(K_X H K_Y H) = \sum_i (K_X H K_Y H)_{i,i}$$

$$= \sum_i \sum_j (K_X H)_{i,j} (K_Y H)_{j,i}$$

$$= \sum_i \sum_j \left\{ \sum_k R_X(x_i, x_j) R_Y(y_i, y_j) - \frac{1}{N} R_X(x_i, x_j) \sum_k R_Y(y_i, y_k) \right. \\ \left. - \frac{1}{N} R_Y(y_i, y_j) \sum_k R_X(x_i, x_k) \right\}$$

$$= \sum_i \sum_j R_X(x_i, x_j) R_Y(y_i, y_j) - \frac{2}{N} \sum_i \sum_j R_X(x_i, x_j) \sum_k R_Y(y_i, y_k) \\ + \frac{1}{N^2} \sum_i \sum_k R_X(x_i, x_k) \sum_j \sum_r R_Y(y_j, y_r)$$

$$= N^2 \widehat{\text{HSIC}}$$

✓

*****問題74*****

```
import numpy as np

def HSIC(x, y, k_x, k_y):
    n = len(x)
    S = 0
    for i in range(n):
        for j in range(n):
            S = S + k_x(x[i], x[j]) * k_y(y[i], y[j])
    T = 0
    for i in range(n):
        T_1 = 0
        for j in range(n):
            T_1 = T_1 + k_x(x[i], x[j])
        T_2 = 0
        for l in range(n):
            T_2 = T_2 + k_y(y[i], y[l])
        T = T + T_1 * T_2
    U = 0
    for i in range(n):
        for j in range(n):
            U = U + k_x(x[i], x[j])
    V = 0
    for i in range(n):
        for j in range(n):
            V = V + k_y(y[i], y[j])
    return S / n**2 - 2 * T / n**3 + U * V / n**4

def HSIC_trace(x, y, k_x, k_y):
    n = len(x)
    K_x = np.zeros((n, n))
    for i in range(n):
        for j in range(n):
            K_x[i, j] = k_x(x[i], x[j])
    K_y = np.zeros((n, n))
    for i in range(n):
        for j in range(n):
            K_y[i, j] = k_y(y[i], y[j])
    E = np.ones((n, n))
    H = np.identity(n) - E / n
    return np.sum(np.diag(np.dot(K_x.dot(H).dot(K_y).dot(H)))) / n**2

if __name__ == "__main__":
    def k_x(x, y):
        return np.exp(-np.linalg.norm(x - y)**2 / 2)

    k_y = k_x
    k_z = k_x

    n = 100
    rs = np.random.RandomState(42)
    for a in [0, 0.1, 0.2, 0.4, 0.6, 0.8]:
        x = rs.randn(n)
        z = rs.randn(n)
        y = a * x + np.sqrt(1 - a**2) * z
        print(f"{{a={a}, {HSIC(x, y, k_x, k_y)}}, {HSIC_trace(x, y, k_x, k_y)}}")
    """
    a=0, HSIC(x, y, k_x, k_y)=0.0016144347904881728, 0.0016144347904855324
    a=0.1, HSIC(x, y, k_x, k_y)=0.0024845938768538467, 0.002484593876853815
    a=0.2, HSIC(x, y, k_x, k_y)=0.0020244572354856105, 0.0020244572354858425
    a=0.4, HSIC(x, y, k_x, k_y)=0.0032241047523186017, 0.003224104752316417
    a=0.6, HSIC(x, y, k_x, k_y)=0.011470114073025228, 0.011470114073027894
    a=0.8, HSIC(x, y, k_x, k_y)=0.019901742290715563, 0.019901742290714505
    """

```

同一の結果が 出力される。

```
"""問題75"""
def HSIC_2(x, y, z, k_x, k_y, k_z):
    n = len(x)
    S = 0
    for i in range(n):
        for j in range(n):
            S = S + k_x(x[i], x[j]) * k_y(y[i], y[j]) * k_z(z[i], z[j])
    T = 0
    for i in range(n):
        T_1 = 0
        for j in range(n):
            T_1 = T_1 + k_x(x[i], x[j])
        T_2 = 0
        for l in range(n):
            T_2 = T_2 + k_y(y[i], y[l]) * k_z(z[i], z[j])
        T = T + T_1 * T_2
    U = 0
    for i in range(n):
        for j in range(n):
            U = U + k_x(x[i], x[j])
    V = 0
    for i in range(n):
        for j in range(n):
            V = V + k_y(y[i], y[j]) * k_z(z[i], z[j])
    return S / n**2 - 2 * T / n**3 + U * V / n**4

if __name__ == "__main__":
    import numpy as np

    def k_x(x, y):
        return np.exp(-np.linalg.norm(x - y)**2 / 2)

    k_y = k_x
    k_z = k_x

    n = 100
    rs = np.random.RandomState(42)
    x = rs.randn(n)
    y = 2 * x + rs.randn(n)
    z = -3 * x + rs.randn(n)

    print(HSIC_2(x, y, z, k_x, k_y, k_z))
# 0.0007463123042284747
```

HSICの値は十分に小さい。

76

- (1). HSIC-1(y-x, z-xy, k-y, k-z)
- (2). HSIC-1(z-x, y-2x, k-z, k-y)
- (3). HSIC-1(z-y, x-yz, k-y, k-z)
- (4). HSIC-1(x-y, z-xy, k-z, k-y)
- (5). HSIC-1(z-y, x-yz, k-z, k-x)
- (6). HSIC-1(xy, z-xy, k-x, k-z)

77.

```

1 # データの生成
2 x = np.random.randn(n)
3 y = np.random.randn(n)
4 u = HSIC_1(x, y, k_x, k_y) ]
5 m = 100
6 w = []
7 for i in range(m):
8     x = x[np.random.choice(n, n, replace=False)]
9     w.append(HSIC_1(x, y, k_x, k_y))
10 v = np.quantile(w, 0.95)
11 x = np.linspace(min(min(w), u, v), max(max(w), u, v), 200)
12
13 density = kde.gaussian_kde(w)
14 plt.plot(x, density(x))
15 plt.axvline(x=v, c="r", linestyle="--")
16 plt.axvline(x=u, c="b")

```

系統計量のHSICを求めます。

爆発収斂に従う
HSICの値を複数得ています。

並び替えると見て、 x_i と y_i の相関が無くなる
であります。つまり無收斂(x, y が独立)が得られます。

78. 積分作用素のカーネル h_2 (命題 53) は、好得な
カーネル (は), 自己実現であるため, 命題 27 が.

固有値 λ_i と固有関数 ϕ_i が存在する。 \square

79. $f(x,y) = \phi(x-y)$, $\phi(t) = e^{-|t|}$
が特性カーネルであることを示す。

$\phi(t)$ の逆 Fourier 変換を用いる。

$$\phi(t) = \int_{-\infty}^{\infty} \frac{2}{1+w^2} e^{iwt} dw$$

ちなみにも、 $\phi(t) = \int_E e^{iwt} d\eta(w)$ の形で表せよ。

また、 η のときは $E = \mathbb{R}$ であるため、

前題 54 から、 $f(x,y) = e^{-|x-y|}$ は特性カーネルである。



$$80. \quad g(w) := (\varepsilon - \|w\|_2)_+^{\frac{(d+1)}{2}}, \quad d = 1 \quad \varepsilon \in \mathbb{C}$$

$$\frac{1}{2\pi} \int_{-\varepsilon}^{\varepsilon} g(w) e^{-iwx} dw = \frac{1 - \cos(x\varepsilon)}{\pi x^2} \quad \text{Erstes}$$

$$\int_{-\varepsilon}^{\varepsilon} (\varepsilon - \|w\|_2)_+ e^{-iwx} dw$$

$$= \varepsilon \int_{-\varepsilon}^{\varepsilon} e^{-iwx} dw - \int_{-\varepsilon}^{\varepsilon} \|w\|_2 e^{-iwx} dw$$

$\approx \mathcal{Z}$

$$\begin{aligned} \int_{-\varepsilon}^{\varepsilon} e^{-iwx} dw &= \int_{-\varepsilon}^{\varepsilon} \cos(wx) dw - i \int_{-\varepsilon}^{\varepsilon} \sin(wx) dw \\ &= 2 \int_0^{\varepsilon} \cos(wx) dw = \frac{2}{x} [\sin(wx)]_0^{\varepsilon} \\ &= \frac{2}{x} \sin(x\varepsilon) \end{aligned}$$

$$\begin{aligned} \int_{-\varepsilon}^{\varepsilon} \|w\|_2 e^{-iwx} dw &= \int_{-\varepsilon}^{\varepsilon} |w| \cos(wx) dw - i \int_{-\varepsilon}^{\varepsilon} |w| \sin(wx) dw \\ &= 2 \int_0^{\varepsilon} w \cos(wx) dw \\ &= 2 \left(\left[\frac{w}{x} \sin(wx) \right]_0^{\varepsilon} - \int_0^{\varepsilon} \frac{1}{x} \sin(wx) dw \right) \\ &= 2 \frac{\varepsilon}{x} \sin(x\varepsilon) + \frac{2}{x} \frac{1}{x} [\cos(x\varepsilon)]_0^{\varepsilon} \\ &= \frac{2\varepsilon}{x} \sin(x\varepsilon) + \frac{2}{x^2} (\cos(x\varepsilon) - 1) \end{aligned}$$

$\delta \rightarrow 0$,

$$\frac{1}{2\pi} \int_{-\varepsilon}^{\varepsilon} (\varepsilon - \|w\|_2)_+ e^{-iwx} dw = \frac{1}{\pi x^2} (1 - \cos(x\varepsilon)) \quad \text{zweites}$$

81. まず、子数型は定義的無限次元多項式カルダルである。2系351、
 E の各コア外集合における普遍カルダルである。

また、三角分布に基づく特性カルダルの台は、 $(-a, a)$ である。2、 E がこの台以外を含むコア外集合であるとき、このカルダルは普遍的である。

定義

カーネルノイズ

$$\begin{aligned}
 R_N(\mathcal{F}) &= \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{F}} \left| \frac{1}{N} \sum_{i=1}^N \sigma_i f(x_i) \right| \right] = \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{F}} \left| \frac{1}{N} \sum_{i=1}^N \sigma_i \langle k(x_i, \cdot), f(\cdot) \rangle_H \right| \right] \\
 &= \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{F}} \left| \left\langle f, \frac{1}{N} \sum_{i=1}^N \sigma_i k(x_i, \cdot) \right\rangle_H \right| \right] \quad \text{（H-内積を外に出さない）} \\
 &\leq \mathbb{E}_\sigma \left[\sup_{f \in \mathcal{F}} \|f\|_H \sqrt{\left\langle \frac{1}{N} \sum_{i=1}^N \sigma_i k(x_i, \cdot), \frac{1}{N} \sum_{i=1}^N \sigma_i k(x_i, \cdot) \right\rangle_H} \right] \\
 &\leq \mathbb{E}_\sigma \left[\sqrt{\frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N \sigma_i \sigma_j k(x_i, x_j)} \right] \\
 &\leq \sqrt{\mathbb{E}_\sigma \left[\frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N k(x_i, x_j) \right]} \leq \sqrt{\frac{k_{max}}{N}}
 \end{aligned}$$

$$\mathbb{E}[\sigma_i \sigma_j] = \delta_{i,j}$$

k_{max} の定義

83

Jensen の
不等式
独立性
 σ, σ'
三角不等式

$$\begin{aligned} & \mathbb{E}_{X,Y} \sup_{f \in \mathcal{F}} \left| \mathbb{E}_{X'} \left\{ \frac{1}{N} \sum_{i=1}^N f(x'_i) - \frac{1}{N} \sum_{i=1}^N f(x_i) \right\} - \mathbb{E}_{Y'} \left\{ \frac{1}{N} \sum_{j=1}^N f(y'_j) - \frac{1}{N} \sum_{j=1}^N f(y_j) \right\} \right| \\ & \leq \mathbb{E}_{X,Y,X',Y'} \sup_{f \in \mathcal{F}} \left| \frac{1}{N} \sum_{i=1}^N f(x'_i) - \frac{1}{N} \sum_{i=1}^N f(x_i) - \frac{1}{N} \sum_{i=1}^N f(y'_i) + \frac{1}{N} \sum_{i=1}^N f(y_i) \right| \\ & = \mathbb{E}_{X,Y,X',Y',\sigma,\sigma'} \sup_{f \in \mathcal{F}} \left| \frac{1}{N} \sum_{i=1}^N \sigma_i \{f(x'_i) - f(x_i)\} + \frac{1}{N} \sum_{i=1}^N \sigma'_i \{f(y'_i) - f(y_i)\} \right| \end{aligned}$$

命題 60
R(F,P)
定義

$$\begin{aligned} & \leq \mathbb{E}_{X,X',\sigma} \sup_{f \in \mathcal{F}} \left| \frac{1}{N} \sum_{i=1}^N \sigma_i \{f(x'_i) - f(x_i)\} \right| + \mathbb{E}_{Y,Y',\sigma'} \sup_{f \in \mathcal{F}} \left| \frac{1}{N} \sum_{j=1}^n \sigma'_j \{f(y'_j) - f(y_j)\} \right| \\ & \leq 2[R(\mathcal{F}, P) + R(\mathcal{F}, Q)] \\ & \leq 2[(k_{max}/N)^{1/2} + (k_{max}/N)^{1/2}] \end{aligned}$$

命題 60 の結果